

## Comparar vec medias 2 poblaciones

Sunday, March 6, 2022 8:13 PM

### ## Comparar vec medias 2 poblaciones ##

Se puede usar el estadístico  $T^2$  para evaluar la igualdad de los vecs. de medias.

Ej:  $\sigma^2 \text{ vs } \rho$

Muestra 1:  $\vec{X}_{11}, \dots, \vec{X}_{1n_1}$   $\vec{X} = \frac{1}{n_1} \sum_{j=1}^{n_1} \vec{X}_{1j}$   
 Población 1  
 obs 1

$$S_1 = \frac{1}{n_1 - 1} \sum_{j=1}^{n_1} (\vec{X}_{1j} - \vec{\bar{X}}_1)' (\vec{X}_{1j} - \vec{\bar{X}}_1)$$

Muestra 2:  $\vec{X}_{21}, \dots, \vec{X}_{2n_2}$

$\vec{\mu}_1$ : Media en pobla<sup>o</sup> 1  
 $\vec{\mu}_2$ : Media en pobla<sup>o</sup> 2. }  $H_0 = \vec{\mu}_1 - \vec{\mu}_2$

#### Suposiciones

1.  $\vec{X}_{11}, \dots, \vec{X}_{1n_1}$  es una m.a de una pobla<sup>o</sup> p-varada con media  $\vec{\mu}_1$ , Cov  $\Sigma_1$ .
2.  $\vec{X}_{21}, \dots, \vec{X}_{2n_2}$  es una m.a de una pobla<sup>o</sup> p-varada con media  $\vec{\mu}_2$ , Cov  $\Sigma_2$ .
3.  $\vec{X}_{11}, \dots, \vec{X}_{1n_1}$  son indep con  $\vec{X}_{21}, \dots, \vec{X}_{2n_2}$   
 • Si n-p grande, es suficiente con esas 3 suposiciones.  
 • n-p NO es grande:  
 4 Poblaciones normales  
 5.  $\Sigma_1 = \Sigma_2$ .

Para hacer la P.H

$$H_0: \vec{\mu}_1 - \vec{\mu}_2 = \delta_0 \quad \text{vs} \quad H_A: \vec{\mu}_1 - \vec{\mu}_2 \neq \delta_0$$

Podemos usar la dist estadística de  $\vec{X}_1 - \vec{X}_2$  a  $\delta_0$

$$E(\vec{X}_1 - \vec{X}_2) = \vec{\mu}_1 - \vec{\mu}_2$$

$$\text{Cov}(\vec{X}_1, \vec{X}_2) = 0 \quad (\text{son indep}).$$

$$\text{Cov}(\vec{X}_1 - \vec{X}_2) = \frac{1}{n_1} \Sigma + \frac{1}{n_2} \Sigma \rightarrow \text{Asumiendo } \Sigma_1 = \Sigma_2 \\ = \left( \frac{1}{n_1} + \frac{1}{n_2} \right) \Sigma$$

Spooled a la estima<sup>o</sup> de  $\Sigma$  cuando hay 2 poblaciones.

$$T^2 = (\vec{X}_1 - \vec{X}_2 - \delta_0)' \left( \left( \frac{1}{n_1} + \frac{1}{n_2} \right) S_{\text{pooled}} \right)^{-1} (\vec{X}_1 - \vec{X}_2 - \delta_0) > C^2$$

C depende de la ~ de  $T^2$

#### Teorema

Si  $\vec{X}_{11}, \dots, \vec{X}_{1n_1}$  es una m.a de tamaño  $n_1$   
 $\vec{X}_{21}, \dots, \vec{X}_{2n_2}$  es una m.a de tamaño  $n_2$ ,  
 de  $\sim N_p(\vec{\mu}_1, \Sigma)$  y  $N_p(\vec{\mu}_2, \Sigma)$  respectivamente.

Entonces,

$$T^2 = (\vec{X}_1 - \vec{X}_2 - \delta_0)' \left( \left( \frac{1}{n_1} + \frac{1}{n_2} \right) S_{\text{pooled}} \right)^{-1} (\vec{X}_1 - \vec{X}_2 - \delta_0)$$

$$\frac{(n_1 + n_2 - 2)p}{(n_1 + n_2 - p - 1)} F_{p, n_1 + n_2 - p - 1}$$

$$P(T^2 \leq \frac{(n_1 + n_2 - 2)p}{(n_1 + n_2 - p - 1)} F_{p, n_1 + n_2 - p - 1}(\alpha)) = 1 - \alpha$$

#### I.C. simultáneos $T^2$

$$\text{sea } C^2 = \frac{(n_1 + n_2 - 2)p}{n_1 + n_2 - p - 1} F_{p, n_1 + n_2 - p - 1}(\alpha)$$

$$a'(\vec{X}_1 - \vec{X}_2) \pm C \sqrt{a' \left( \frac{1}{n_1} + \frac{1}{n_2} \right) S_{\text{pooled}} a}$$

1 -  $\alpha$  contendrá el val. real de  $a'(\vec{X}_1 - \vec{X}_2)$

#### I. Bonferroni con confianza $(1 - \alpha)$

Simultáneos para la variable  $i$

$$(\bar{x}_{1i} - \bar{x}_{2i}) \pm t_{n_1+n_2-2} \left( \frac{s}{\sqrt{2p}} \right) \sqrt{\left( \frac{1}{n_1} + \frac{1}{n_2} \right)} \text{ Si pooled}$$

Caso  $\Sigma_1 \neq \Sigma_2$  } Se necesita  $n-p$  grande.

Si los tamaños de las muestras satisfacen que  $(n_1-p)$  y  $(n_2-p)$  grandes. La  $(1-\alpha)\%$  elipse de confianza para  $\mu_1 - \mu_2$  está dada por los vals de  $\mu_1 - \mu_2$  que satisfacen

$$(\bar{x}_1 - \bar{x}_2 - (\mu_1 - \mu_2))' \left( \frac{1}{n_1} S_1 + \frac{1}{n_2} S_2 \right)^{-1} (\bar{x}_1 - \bar{x}_2 - (\mu_1 - \mu_2)) \leq \chi_p^2(\alpha)$$

matriz

Lo mismo para las comb. lin. a' ( $\mu_1 - \mu_2$ ), los IC son dados por:

$$a'(\bar{x}_1 - \bar{x}_2) \pm \sqrt{\chi_p^2(\alpha)} \sqrt{a' \left( \frac{1}{n_1} S_1 + \frac{1}{n_2} S_2 \right) a}$$

$$s_{\text{pooled}} = \frac{(n_1-1)S_1 + (n_2-1)S_2}{n_1 + n_2 - 2}$$

## ## MANOVA ##

**ANOVA** . Veo si mis poblaciones son iguales o no.

Análisis de varianza → veo si las dif. en medias se deben a sus varianzas o que son ≠ pob.  
la variabilidad entre los grupos o la variabilidad interna de el grupo.

Se busca comparar más de 2 poblaciones.

Pop 1:  $x_{11} \dots x_{1n_1}$  →  $n$  obs con  $p$  vars en la pobla° 1.

Pop  $g$ :  $x_{g1} \dots x_{gn_g}$  → " " "  $g$ .

Buscamos investigar cuáles medias poblacionales son = y si no, cuáles son ≠.

Suposiciones:

1.  $x_{l1}, \dots, x_{ln_l}$  es una m.a de tamaño  $n_l$  de una pobla° con media  $\mu_l$   $l=(1, \dots, g)$  indep. entre poblaciones (las muestras de el pobla° es indep a las demás)
2. Todas las poblaciones tienen la misma varianza  $\Sigma$ .
3. Todas las poblaciones son  $N_p$  normales multivar.

## ANOVA (univar)

$x_{l1}, \dots, x_{ln_l}$  m.a de  $N(\mu_l, \sigma^2)$   $l=(1, \dots, g)$  → muestra indep.

Buscamos evaluar  $\mu_1 = \mu_2 = \dots = \mu_g$

$$\mu_l = \underbrace{\mu}_{\text{media general}} + \underbrace{\tau_l}_{\text{desvía o efecto asoc. a la pobla° l (tratamiento l)}}$$

Para nuestra P.H:  $H_0: \mu_1 = \dots = \mu_g \leftrightarrow \tau_1 = \dots = \tau_g = 0$ .

$x_{lj} \sim (\mu + \tau_l, \sigma^2) \Rightarrow x_{lj} = \mu + \tau_l + e_{lj}$  error aleatorio

• Tenemos q' fijar  $q$ :  $e_{lj} \sim N(0, \sigma^2)$  (son indep entre ellas)

$$\sum_{l=1}^g n_l \tau_l = 0$$

• Descomponemos el obs como:

$$x_{lj} = \bar{x} + (\bar{x}_l - \bar{x}) + (x_{lj} - \bar{x}_l)$$

(obs)      media total      efecto del trat  $\tau_l$       error: val obs  $e_{lj}$  media en tratam.

Rechazamos  $H_0$  si la contrib° de los tratamientos es grande relativo a los residuos

→ El tratamiento si está haciendo efecto.

Como medida de tamaño de la contrib° se calculan las sumas de cuadrados de las obs  $SS$ .

$$SS_{\text{obs}} = SS_{\text{total}} = \sum_{l=1}^g \sum_{j=1}^{n_l} x_{lj}^2$$

$$SS_{\text{mean}} = \sum_{l=1}^g \sum_{j=1}^{n_l} \bar{x}^2 = \left( \sum_{l=1}^g n_l \right) \bar{x}^2$$

$\hat{\sigma} \rightarrow$  estima°.

$$SS_{\text{treatm}} = \sum_{l=1}^g \sum_{j=1}^{n_l} \hat{\tau}_l^2 = \sum_{l=1}^g (\bar{x}_l - \bar{x})^2$$

$$SS_{\text{residue}} = \sum_{l=1}^g \sum_{j=1}^{n_l} \hat{e}_{lj}^2 = \sum_{l=1}^g \sum_{j=1}^{n_l} (x_{lj} - \bar{x}_l)^2$$

$$SS_{corrected} = SS_{obs} - SS_{mean} = SS_{treatm} + SS_{residue}$$

Sea  $n = n_1 + \dots + n_k$  (suma de TOTAL muestra)

Source of variance	SS	gl
Treatment	$SS_{treatm}$	$g - 1$
Residual	$SS_{residue}$	$n - g$
Total (corrected)	$SS_{corrected}$	$n - 1$

$$F = \frac{SS_{treatm} / (g-1)}{SS_{residue} / (n-g)} \sim F_{(g-1), (n-g)}(\alpha)$$

Si  $F$  grande  $\rightarrow$  rechazo  $H_0$   
 La fuente de variabilidad de los tratam. es mayor a los residuos.

Ej: Pob 1: 9, 6, 9

Pob 2: 0, 2

Pob 3: 3, 1, 2

$$\begin{matrix} \text{Pob 1} \\ \text{Pob 2} \\ \text{Pob 3} \end{matrix} \begin{bmatrix} 4 & 6 & 9 \\ 0 & 2 & \\ 3 & 1 & 2 \end{bmatrix} = \begin{bmatrix} 4 & 4 & 4 \\ 4 & 4 & 4 \\ 4 & 4 & 4 \end{bmatrix} + \begin{bmatrix} 4 & 4 & 4 \\ -3 & -3 & -3 \\ -2 & -2 & -2 \end{bmatrix} + \begin{bmatrix} 1 & -2 & 1 \\ -1 & 1 & -1 \\ 1 & -1 & 0 \end{bmatrix}$$

$$SS_{tr} = 78 \quad | \quad g-1 = 3-1 = 2$$

$$SS_{res} = 10 \quad | \quad n-g = (3+2+3)-3 = 5$$

$$F = \frac{SS_{tr} / (g-1)}{SS_{res} / (n-g)} = 19.5 > F_{2,5}(0.01) = 13.27$$

$\rightarrow$  El tratam. 11 tiene efecto  
 $\Rightarrow$  Rechazo  $H_0: \tau_1 = \tau_2 = \tau_3 = 0$

$$\begin{bmatrix} 9 & 0 & 3 \\ 6 & 2 & 1 \\ 9 & 1 & 2 \end{bmatrix}$$

$$4 \approx \frac{32}{8} = 4$$

$$\bar{x}_L - \bar{x} = \begin{bmatrix} 4 & -3 & -2 \\ \vdots & \vdots & \vdots \\ \vdots & \vdots & \vdots \end{bmatrix}$$

$$x_{Lj} - \bar{x}_L = \begin{bmatrix} 1 & -1 & 1 \\ -2 & 1 & -1 \\ 1 & 0 & 0 \end{bmatrix}$$

Comparación de medias  
 con ANOVA.

$$\begin{matrix} \text{Ej:} \\ \text{Pob 1} \\ \text{Pob 2} \\ \text{Pob 3} \end{matrix} = \begin{matrix} 9, 6, 9 \\ 0, 2 \\ 3, 1, 2 \end{matrix}$$

$$\bar{X} = \frac{9+6+9+0+2+3}{8}$$

$$\bar{X} = 4.$$

$$\bar{x}_1 = 24 / 3 = 8$$

$$\bar{x}_2 = 2 / 2 = 1$$

$$\bar{x}_3 = 6 / 3 = 2$$

$$x_{Lj} - \bar{x}_L = \begin{bmatrix} 1 & -2 \\ -1 & 1 \\ 1 & -1 \end{bmatrix}$$

$$F = \frac{SS_{treatment} / 1}{SS_{residue} / (n-g)}$$

$$SS_{treat} = \sum (\bar{x}_L - \bar{x})^2$$

$$SS_{residue} = \sum (x_{Lj} - \bar{x}_L)^2$$

$$F = \frac{78 / 2}{10 / 5} = \frac{39}{2}$$

$$F_{g-1, n-g}(0.01)$$

Como  $F > F_{g-1, n-g}(0.01)$

de gl hayā 19

$$\begin{aligned}
 SST &= \sum (\bar{x}_i - \bar{x})^2 \\
 &= 3(16) + 2(9) + 12 \\
 &= 78
 \end{aligned}$$

$$\begin{aligned}
 SS_{res} &= \sum (x_{ij} - \bar{x}_i)^2 \\
 &= 6(1) + 4 = 10
 \end{aligned}$$