

# Clasificación de varias poblaciones

Wednesday, May 11, 2022 2:18 PM

## ## Clasificación de varias poblaciones ##

Buscamos generalizar  $g \geq 2$

Sea  $f_i(x)$  la densidad de  $\pi_i$

!  $P_i$ : Probabilidad

!  $C(k|i)$ : Clasificar como  $\pi_k$  cuando es  $\pi_i$

$C(i|i) = 0$

$P(k|i) = P(\text{clasif. como } \pi_k \mid \text{siendo } \pi_i) = \int_{R_k} f_i(x) dx$

$$P(i|i) = 1 - \sum_{\substack{k=1 \\ k \neq i}}^g P(k|i)$$

Entonces, el TPM de un  $x$  de  $\pi_i$  es:

$$\text{TPM}(i) = \sum_{\substack{k=1 \\ k \neq i}}^g P(k|i) C(k|i) \rightarrow \text{Minimizar}$$

$$\begin{aligned} \text{TPM} &= P_1 \text{TPM}(1) + \dots + P_g \text{TPM}(g) \\ &= \sum_{i=1}^g P_i \sum_{\substack{k=1 \\ k \neq i}}^g P(k|i) C(k|i) \end{aligned}$$

Para determ.  $R_1, \dots, R_g$  mutuam. excluyentes y exhaustivas, buscamos minimizar TPM.

Tco: TPM se minimiza si la regla de clasificac° es:

Clasificar  $x$  como  $\pi_k$   $k=1, \dots, g+g$

$\sum_{i=1}^g P_i f_i(x) C(k|i)$  es mínima.  $\Rightarrow$  si queremos ver en la pobla°  $i$ , pruebo en todas las demás. Donde sea menor (o equivoco, ahí es!

Obs: Si los costos de clasificac° son =:

$$\sum_{i=1}^g P_i f_i(x) \rightarrow \text{se clasifica } x_0 \text{ como } \pi_k \text{ si: } P_k f_k(x) \geq P_i f_i(x) \quad \forall i \neq k$$

• Proba de asignar a una nueva obs ( $x_0$ ):

$$P(\pi_k | x_0) = \frac{P_k f_k(x_0)}{\sum_{i=1}^g P_i f_i(x_0)} \rightarrow \begin{aligned} &\text{Casos favorables} \\ &\text{Casos totales} \end{aligned} \quad \left. \begin{array}{l} \text{si los costos} \\ \text{son =} \\ \text{si no? TAREA.} \end{array} \right\}$$

- Con costos  $\neq$ :

Obs: Si las poblaciones son normales con media  $\mu_i$  y cov  $\Sigma_i$ , y hay costos =.

Clasificar  $x$  como  $\pi_k$  si:

$$\ln(P_k f_k(x)) = \ln(P_k) - \frac{P}{2} \ln(2\pi) - \frac{1}{2} \ln|\Sigma_k| - \frac{1}{2} (x - \mu_k)' \Sigma_k^{-1} (x - \mu_k) \rightarrow \text{f° discrimin. } d_k^a(x)$$

Lo clasificamos en la pobla°  $i$ , donde la f° discriminante sea máxima.

$$\max_i (\ln(P_i f_i(x)))$$

Obs: Si  $\mu_i$  y  $\Sigma_i$  desconocida, pero tenemos un conjunto de entrenamiento.

- $\bar{x}_i$ : media muestral de  $\pi_i$
- $S_i$ : Cov muestral de  $\pi_i$
- $n_i$ : Tamaño de la muestra  $\pi_i$

$$\hat{d}_i^a(x) = -\frac{1}{2} \ln|S_i| - \frac{1}{2} (x - \bar{x}_i)' S_i^{-1} (x - \bar{x}_i) + \ln(P_i) - \frac{P}{2} \ln(2\pi)$$

• Se puede clasificar  $x_0$  como  $\pi_k$  cuando  $\hat{d}_k^a(x) = \max_i \hat{d}_i^a(x)$ .

• Si todas las  $\Sigma_i$  son =,

$$d_i^a(x) = \mu_i' \Sigma^{-1} x - \frac{1}{2} \mu_i' \Sigma^{-1} \mu_i + \ln(P_i)$$

Lo podemos escribir con:

$$\hat{d}_i^a(x) = \bar{x}_i' S_{\text{pooled}}^{-1} x - \frac{1}{2} \bar{x}_i' S_{\text{pooled}}^{-1} \bar{x}_i + \ln(P_i)$$

$$S_{pooled} = \frac{1}{n_1 + \dots + n_g - g} ((n_1 - 1)S_1 + \dots + (n_g - 1)S_g)$$

**Método discriminante de Fisher** → No necesita normalidad  
 → Necesita varianzas =  $\Sigma_1 = \Sigma_2 = \dots = \Sigma$   
 Usar pocas comb. lin  $a'_1 x_1, \dots, a'_k x_k$  para lograr clasificar en varias poblaciones (y sirve a reducir dimensionalidad).  
 $\downarrow$   
 invertible

Sea  $\bar{\mu}$  la media de la media de las pobla<sup>o</sup>es combinadas.

$$\bar{\mu} = \frac{1}{g} \sum_{i=1}^g \mu_i$$

$$\text{Sea } B_{\mu} = \sum_{i=1}^g (\mu_i - \bar{\mu})(\mu_i - \bar{\mu})'$$

Sea  $Y = a'x$  comb lineal

$$E[Y | \pi_i] = a' E[x | \pi_i] = a' \mu_i \quad \bullet \text{Var}(Y) = a' \Sigma a \text{ de las pobla}^o\text{es.}$$

$\mu_{iy} = a' \mu_i$  depende de la pobla<sup>o</sup> a la q' pertenece.

$$\bar{\mu}_y = \frac{1}{g} \sum_{i=1}^g \mu_{iy} = \frac{1}{g} \sum_{i=1}^g a' \mu_i = a' \bar{\mu}$$

$$\text{Definimos } \frac{\sum_{i=1}^g (\mu_{iy} - \bar{\mu}_y)^2}{g y^2} = \frac{\sum_{i=1}^g (a' \mu_i - a' \bar{\mu})^2}{a' \Sigma a} = \frac{a' B_{\mu} a}{a' \Sigma a} \quad \textcircled{0}$$

var entre grupos en rela<sup>o</sup> con la var dentro de los grupos.

⊕ Busco un vec a que maximice

Si  $\mu_i$  y  $\Sigma$  desconocidos, y el conjunto de entrenam. tiene  $n_i$  obs de  $\pi_i$ .

Los datos de  $\pi_i$  son:  $x_i = \begin{bmatrix} x_{i1} \\ \vdots \\ x_{in_i} \end{bmatrix}$  con  $\bar{x}_i = \frac{1}{n_i} \sum_{j=1}^{n_i} x_{ij}$

$$\bar{x} = \frac{1}{g} \sum_{i=1}^g \bar{x}_i$$

$$\bullet B = \sum_{i=1}^g (\bar{x}_i - \bar{x})(\bar{x}_i - \bar{x})'$$

(estimador  $B_{\mu}$ )

$$\text{Definimos } W = \sum_{i=1}^g \sum_{j=1}^{n_i} (x_{ij} - \bar{x}_i)(x_{ij} - \bar{x}_i)'$$

$$= \frac{W}{n_1 + \dots + n_g - g} = S_{pooled} \text{ (estimador de } \Sigma)$$

Ley discm. de Fisher: → varianzas = .

Sean  $\hat{\lambda}_1, \dots, \hat{\lambda}_s > 0$  los  $s \leq \min(g-1, p)$  vals propios de  $W^{-1}B$  asoc. a  $\hat{e}_1, \dots, \hat{e}_s$  vecs propios normalizados t.q.

$$\hat{e}_i' S_{pooled} \hat{e}_i = 1$$

Entonces, el a q' maximiza  $\frac{\hat{a}' B \hat{a}}{\hat{a}' W \hat{a}}$  es  $\hat{a}_1 = \hat{e}_1$

- $\hat{a}_1' x$  es el 1er discriminante muestral
- $\hat{a}_k' x$  produce el k-ésimo discm. muestral ( $k \leq s$ )

Clasifica<sup>o</sup> discm. Fisher

Los discriminantes buscan otorgar representa<sup>o</sup> de baja dimensionalidad q' separe pobla<sup>o</sup>es lo mejor posible.

$Y_k = a'_k x$  el k-ésimo discm ( $k \leq s$ )

$Y = \begin{bmatrix} Y_1 \\ \vdots \\ Y_s \end{bmatrix}$  tiene media  $\mu_{iy}$  para  $\pi_i$

$$\bullet \text{COV}(Y) = \Sigma \quad \text{TAREA}$$

$$\text{Luego, } (Y - \mu_{iy})'(Y - \mu_{iy}) = \sum_{j=1}^s (y_j - \mu_{iyj})^2 \quad \textcircled{0}$$

mide las distancias.

Podemos clasificar  $Y$  a  $\pi_k$  si  $\textcircled{0}$  es mínimo.

↳ Clasificar  $x$  como  $\pi_k$  si:

$$\bullet \sum_{j=1}^s (y_j - \mu_{kyj})^2 = \sum_{j=1}^s (a_j' (x - \mu_k))^2$$

$$= \sum_{j=1}^g (a_j' (x - \mu_i))^2 \quad \forall i \neq k$$

usando r discriminantes

$$\text{Obs: } s_1 \ p_1 \ \dots \ p_g = \frac{1}{g}$$